MACHINE LEARNING: KNN, Random Forest e Gradient Boosting

Prof. Reinaldo de Souza Júnior

reinaldosouza.senai@fieg.com.br

DEFINIÇÃO

- Machine Learning é o conceito de ensinar máquinas a executar tarefas com ou sem supervisão, prevendo um resultado de acordo com os parâmetros informados.

SUPERVISED LEARNING X UNSUPERVISED LEARNING

- **SUPERVISED LEARNING**: temos os e-mails de spam e não spam, que se trata de um caso de Machine Learning com supervisão, onde nós temos um resultado esperado para a nossa previsão: se o e-mail recebido é spam ou não.
- **UNSUPERVISED LEARNING**: imagine um modelo que deseja saber a melhor rota para um carro chegar ao seu destino. Esse é um caso de Unsupervised Learning, onde não há um resultado esperado ou resposta certa.

CLASSIFICATION X REGRESSION/PREDICTION

- A **classificação** é uma sub-categoria de aprendizagem supervisionada. Classificação é o processo de tomar algum tipo de entrada e atribuir um rótulo a ela. Sistemas de classificação são usados geralmente quando as previsões são de natureza distinta, ou seja, um simples “sim ou não”. Exemplo: Mapeamento de uma imagem de uma pessoa e classificação como masculino ou feminino.
- Outra sub-categoria de aprendizagem supervisionada usada quando o valor que está sendo previsto difere de um “sim ou não” e que siga um espectro contínuo. Sistemas de **regressão** poderiam ser usados, por exemplo, para responder às perguntas: “Quanto custa?” ou “Quantos existem?”

MODELO DE UTILIZAÇÃO DOS ALGORITMOS

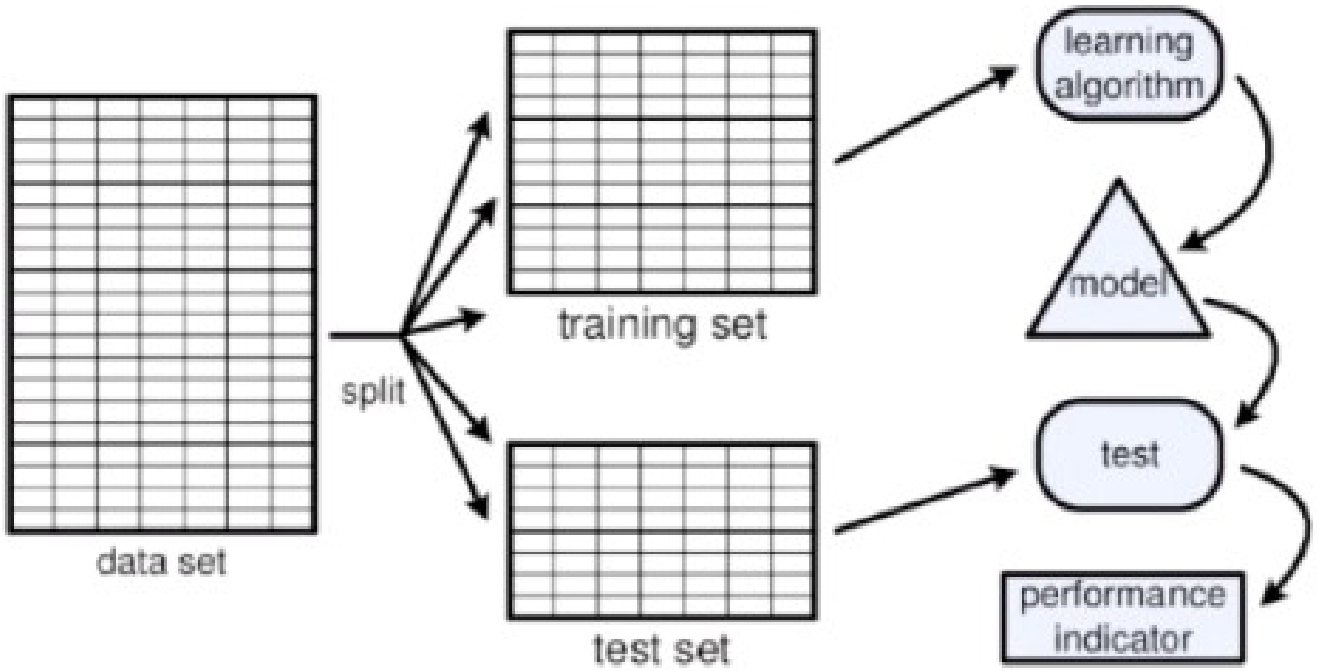

KNN - K-NEAREST NEIGHBOR

- É um algoritmo muito útil para modelos de Classificação e Regressão.

- O KNN funciona da seguinte forma: primeiro, ele mapeia os dados já contidos no dataset. Depois, quando o modelo está pronto e novas informações são inseridas para serem previstas, o código verifica qual é o ponto mais próximo daquele novo dado.

KNN - K-NEAREST NEIGHBOR

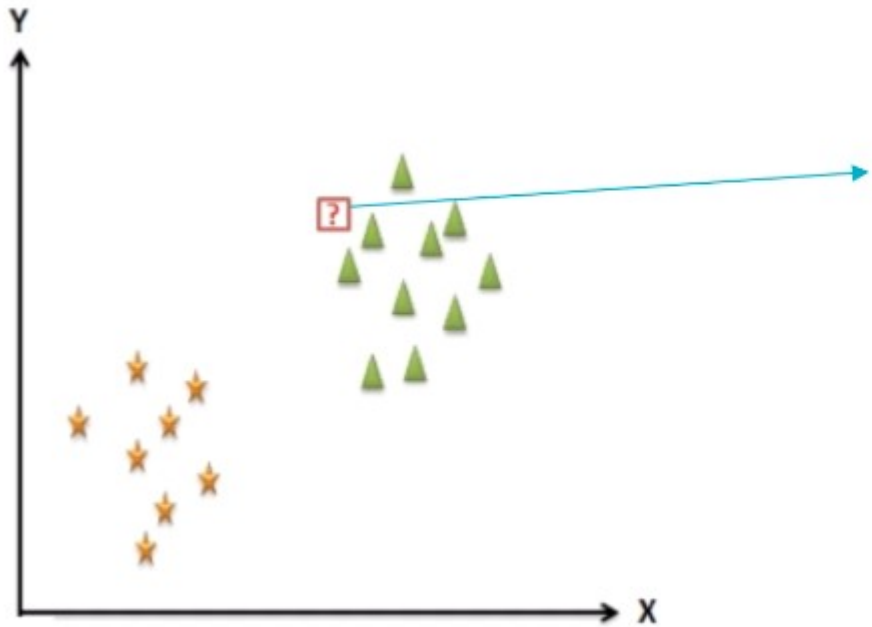

A qual das duas classes (estrelas ou triângulos) pertence este ponto de dado?

O algoritmo KNN utiliza medidas de distância a fim de comparar os pontos de dados

KNN - K-NEAREST NEIGHBOR

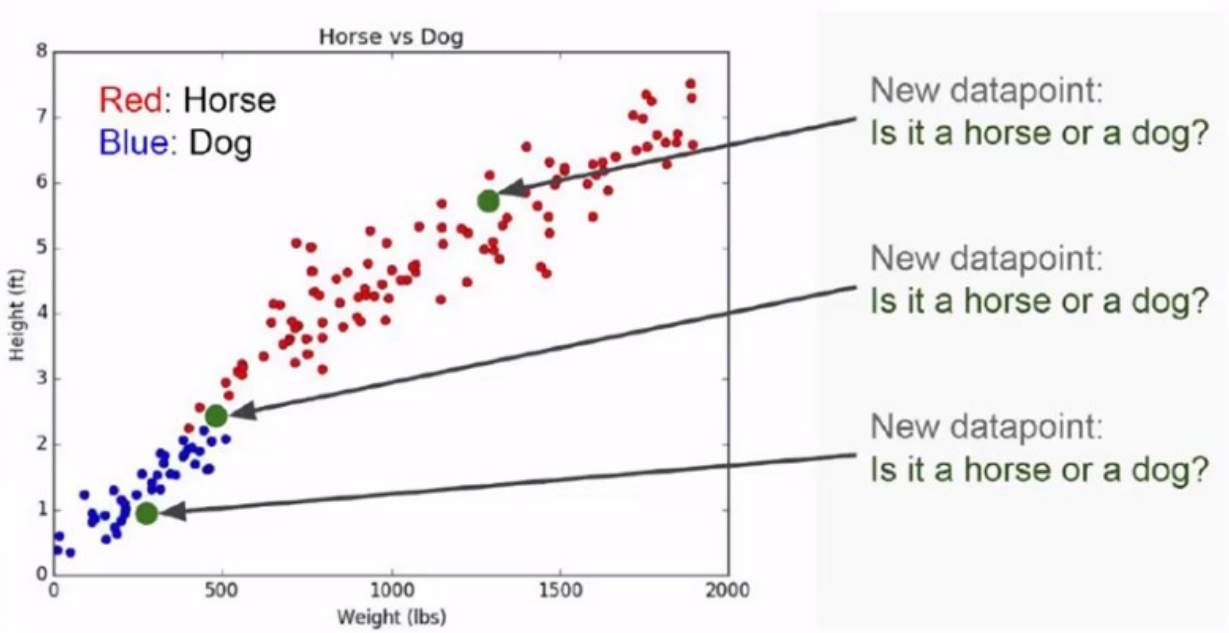

KNN - K-NEAREST NEIGHBOR

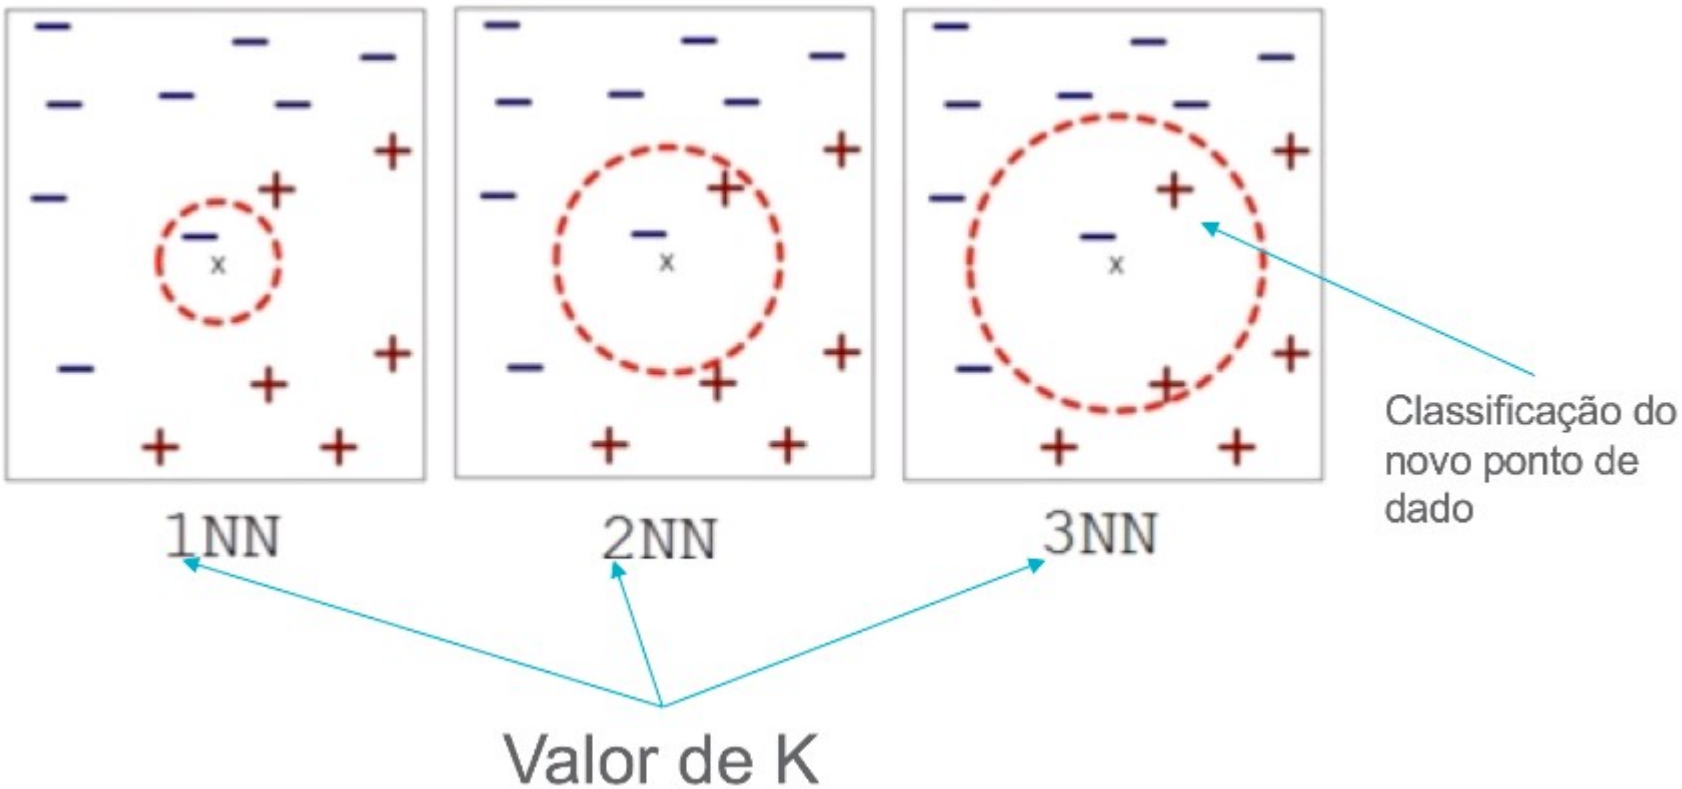

RANDOM FOREST

- Random Forest ou árvores de decisão representam uma das formas mais simplificadas de um sistema de suporte à decisão. É um método estatístico, de aprendizagem supervisionada, podendo ser utilizado em problemas de classificação e na realização de previsões.

- A partir de um conjunto de dados existente, o método cria uma representação do conhecimento ali embutido, em formato de árvore. Os nós da árvore são criados a partir das características (features) do conjunto de dados.

RANDOM FOREST

Exemplos de Treino

Dia	Aspecto	Temp.	Humidade	Vento	Jogar Ténis
D1	Sol	Quente	Elevada	Fraco	Não
D2	Sol	Quente	Elevada	Forte	Não
D3	Nuvens	Quente	Elevada	Fraco	Sim
D4	Chuva	Ameno	Elevada	Fraco	Sim
D5	Chuva	Fresco	Normal	Fraco	Sim
D6	Chuva	Fresco	Normal	Forte	Não
D7	Nuvens	Fresco	Normal	Fraco	Sim
D8	Sol	Ameno	Elevada	Fraco	Não
D9	Sol	Fresco	Normal	Fraco	Sim
D10	Chuva	Ameno	Normal	Forte	Sim
D11	Sol	Ameno	Normal	Forte	Sim
D12	Nuvens	Ameno	Elevada	Forte	Sim
D13	Nuvens	Quente	Normal	Fraco	Sim
D14	Chuva	Ameno	Elevada	Forte	Não

Árvore de Decisão para Jogar Ténis

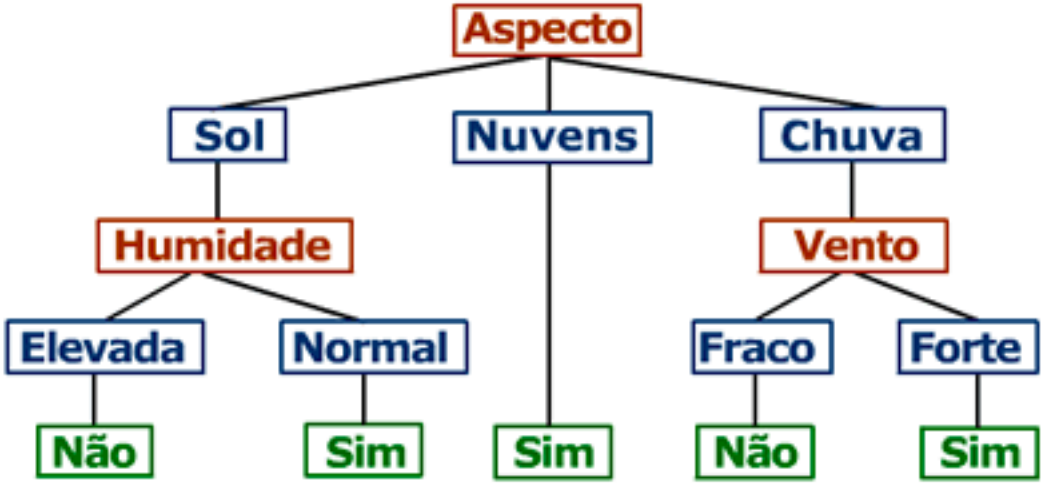

RANDOM FOREST

Exemplos de Treino

Dia	Aspecto	Temp.	Humidade	Vento	Jogar Ténis
D1	Sol	Quente	Elevada	Fraco	Não
D2	Sol	Quente	Elevada	Forte	Não
D3	Nuvens	Quente	Elevada	Fraco	Sim
D4	Chuva	Ameno	Elevada	Fraco	Sim
D5	Chuva	Fresco	Normal	Fraco	Sim
D6	Chuva	Fresco	Normal	Forte	Não
D7	Nuvens	Fresco	Normal	Fraco	Sim
D8	Sol	Ameno	Elevada	Fraco	Não
D9	Sol	Fresco	Normal	Fraco	Sim
D10	Chuva	Ameno	Normal	Forte	Sim
D11	Sol	Ameno	Normal	Forte	Sim
D12	Nuvens	Ameno	Elevada	Forte	Sim
D13	Nuvens	Quente	Normal	Fraco	Sim
D14	Chuva	Ameno	Elevada	Forte	Não

Árvore de Decisão para Jogar Ténis

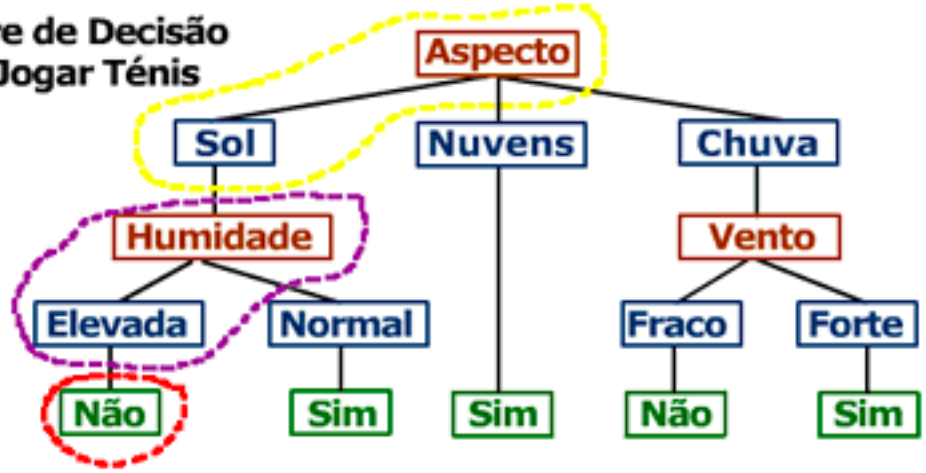

Dia	Aspecto	Temp.	Humidade	Vento	Jogar Ténis
D1	Sol	Quente	Elevada	Fraco	Não

GRADIENT BOOSTING

- O algoritmo Gradient Boosting é um técnica Boosting, incluída dentro do grupo de classificadores Ensemble. Esses classificadores são métodos que utilizam uma combinação de resultados de preditores fracos, com o objetivo de produzir um melhor modelo preditivo. Os preditores fracos são modelos que, quando utilizados individualmente possuem uma acurácia abaixo do esperado.

- O gradient boosting é uma técnica de aprendizado de máquina para problemas de regressão e classificação, que produz um modelo de previsão na forma de um ensemble de modelos de previsão fracos, geralmente árvores de decisão. Ela constrói o modelo em etapas, como outros métodos de boosting, e os generaliza, permitindo a otimização de uma função de perda diferenciável arbitrária.

Vamos Codar ☺

DICAS DE LIVRO

DICAS DE CURSOS

Udemy

UDACITY

Data Science
Academy