Trabalho Prático – ETL e Armazenamento em Banco de Dados Não Relacional

Objetivo

Construir um pipeline para coletar, tratar, armazenar e consultar dados da base `BD_Producao_Artistica`, utilizando **MongoDB** como banco principal.

Link do dataset:
https://huggingface.co/datasets/Willgnner-Santos/BD_Producao_Artistica

Para baixar os dados, vocês devem entrar no link e clicar em "**Arquivos e versões**".

Posteriormente, vocês vão conseguir baixar os **JSONL**.

Etapa 1 — Entender a base

O grupo deve identificar:

- quais arquivos existem;
- o que cada um representa;
- como os dados se relacionam;
- quais campos parecem problemáticos.

Aqui, sem formalismo demais.
É mais uma leitura técnica da base.

Etapa 2 — Carregar os dados brutos

Os alunos deverão desenvolver uma etapa de ingestão de dados para o MongoDB. Durante as aulas, foram apresentados alguns exemplos de como realizar essa ingestão, que podem servir como referência inicial. No entanto, é importante destacar que esses exemplos não devem limitar a abordagem adotada, os alunos são incentivados a explorar diferentes estratégias, ferramentas e arquiteturas para implementar a ingestão de dados de forma eficiente e adequada ao problema proposto (**pode envolver pesquisa**).

Sugestão de coleções

- `raw_producao`
- `raw_pessoa`
- `raw_equipe`

A ideia aqui é guardar o dado **como veio**, quase sem tratamento.

Etapa 3 — Fazer o tratamento

Vocês devem tratar problemas como:

- tipos incorretos;
- campos vazios;
- registros duplicados;
- anos inválidos;
- textos inconsistentes;
- ids sem correspondência;
- papéis nulos ou estranhos.

Exemplos:

- quais problemas encontraram;
- como trataram;
- o que decidiram manter;
- o que decidiram descartar.

Etapa 4 — Criar a versão tratada no MongoDB

Depois da limpeza, coleções “finais”, por exemplo:

- `producao_clean`
- `pessoa_clean`
- `equipe_clean`

Ou até uma versão mais documental, como:

- `producoes_com_participantes`

Se quiserem deixar mais interessante, vocês podem escolher entre:

- manter as coleções separadas;
- ou montar documentos mais ricos com dados aninhados.

Etapa 5 — Consultas no banco não relacional

Exibir pelo menos:

- 3 consultas simples com filtro;
- 2 agregações;
- 1 ranking;
- 1 consulta que mostre a vantagem ou dificuldade do modelo escolhido.

Exemplos

- quantidade de produções por tipo;
- quantidade de pessoas por produção;
- top pessoas com mais participações;
- anos com mais produções;
- papéis mais frequentes.

Etapa 6 — Comparação com banco relacional

O grupo deve pegar uma parte da base ou completa e subir também no PostgreSQL, só para comparar:

- como ficou o armazenamento;
- como ficaram as consultas;
- o que foi mais fácil no MongoDB;
- o que foi mais fácil no SQL.

Importante

Isso é **comparativo**, não o foco principal.

Etapa 7 — Docker, GitHub e documentação

Entrega com:

- código no GitHub;
- `docker-compose.yml`;
- MongoDB rodando;
- scripts de ingestão e tratamento;
- README explicando como executar;
- relatório do processo.

Itens obrigatórios

- uso de **MongoDB/PostgreSQL**;
- ingestão dos arquivos;
- tratamento de dados;
- armazenamento bruto e tratado;
- consultas e agregações;
- Docker;
- GitHub;
- documentação.

Opcional

- Redis como cache ou apoio;
- interface simples;
- dashboard.

Estrutura sugerida

```
trabalho_nosql/
├── data/
├── src/
│   ├── ingest.py
│   ├── clean.py
│   ├── load.py
│   └── queries.py
├── docker/
│   └── docker-compose.yml
├── docs/
│   ├── problemas_encontrados.md
│   ├── decisoes_tecnicas.md
│   └── comparacao_opcional_sql.md
└── README.md
```

Critérios de avaliação

- **Ingestão dos dados** — 2,0
- **Tratamento/qualidade dos dados** — 2,0
- **Armazenamento no MongoDB/PostgreSQL** — 2,0
- **Consultas e agregações** — 1,0
- **Docker + GitHub** — 1,0
- **Documentação** — 2,0
    - Total de **10 pontos**.

Recomendação final

O foco do trabalho é o banco não relacional. O MongoDB será o banco principal da solução. O uso de banco relacional serve apenas para comparação.